



CIFAR-10 Veri Setinde CNN Model Geliřtirme

Özlem Nur Duman



CIFAR-10

CIFAR-10 veri seti, 10 farklı sınıfa ait 60,000 renkli görüntüden oluşan ve görüntü sınıflandırma alanında yaygın olarak kullanılan bir veri setidir. Sınıflar arasında uçak, otomobil, kuş, kedi, geyik, köpek, kurbağa, at, gemi ve kamyon gibi çeşitli nesne kategorileri bulunmaktadır.





Proje Amacı

- Bu proje, CIFAR-10 veri setini kullanarak Yapay Zekaya Giriş programı çerçevesinde bir Convolutional Neural Network (CNN) modeli geliştirmek ve bu modeli eğiterek görüntü sınıflandırma görevinde yüksek doğruluk elde etmek için geliştirilmiştir.

Prosedür

- Kütüphaneleri İçe Aktarma
- Veri Setini Yükleme
- Veri Önişleme
- Veri Görselleştirme
- CNN Model Geliştirme
- Veri Artırma (Data Augmentation)
- Reinforcement Learning
- Veri Doğrulama



Veri Ön işleme ve Görselleştirme

İlk adımda veri setini indirip train set/ test set olarak ayırdıktan sonra veri ön işleme adımına geçilir. Bu adımda görsel veri seti ile ilgilendiğimiz için önce verilerimizi 255'e yani bir pixelin en büyük boyutuna bölerek veriyi normalleştirmeye yol hazırlanır.

Devamında, kullanılan veri seti birden çok sınıfa sahip olduğu için etiket görevi gören veriler to_categorical kullanarak one-hot encoding formatına dönüştürülerek kullanıma hazır hale getirilir.

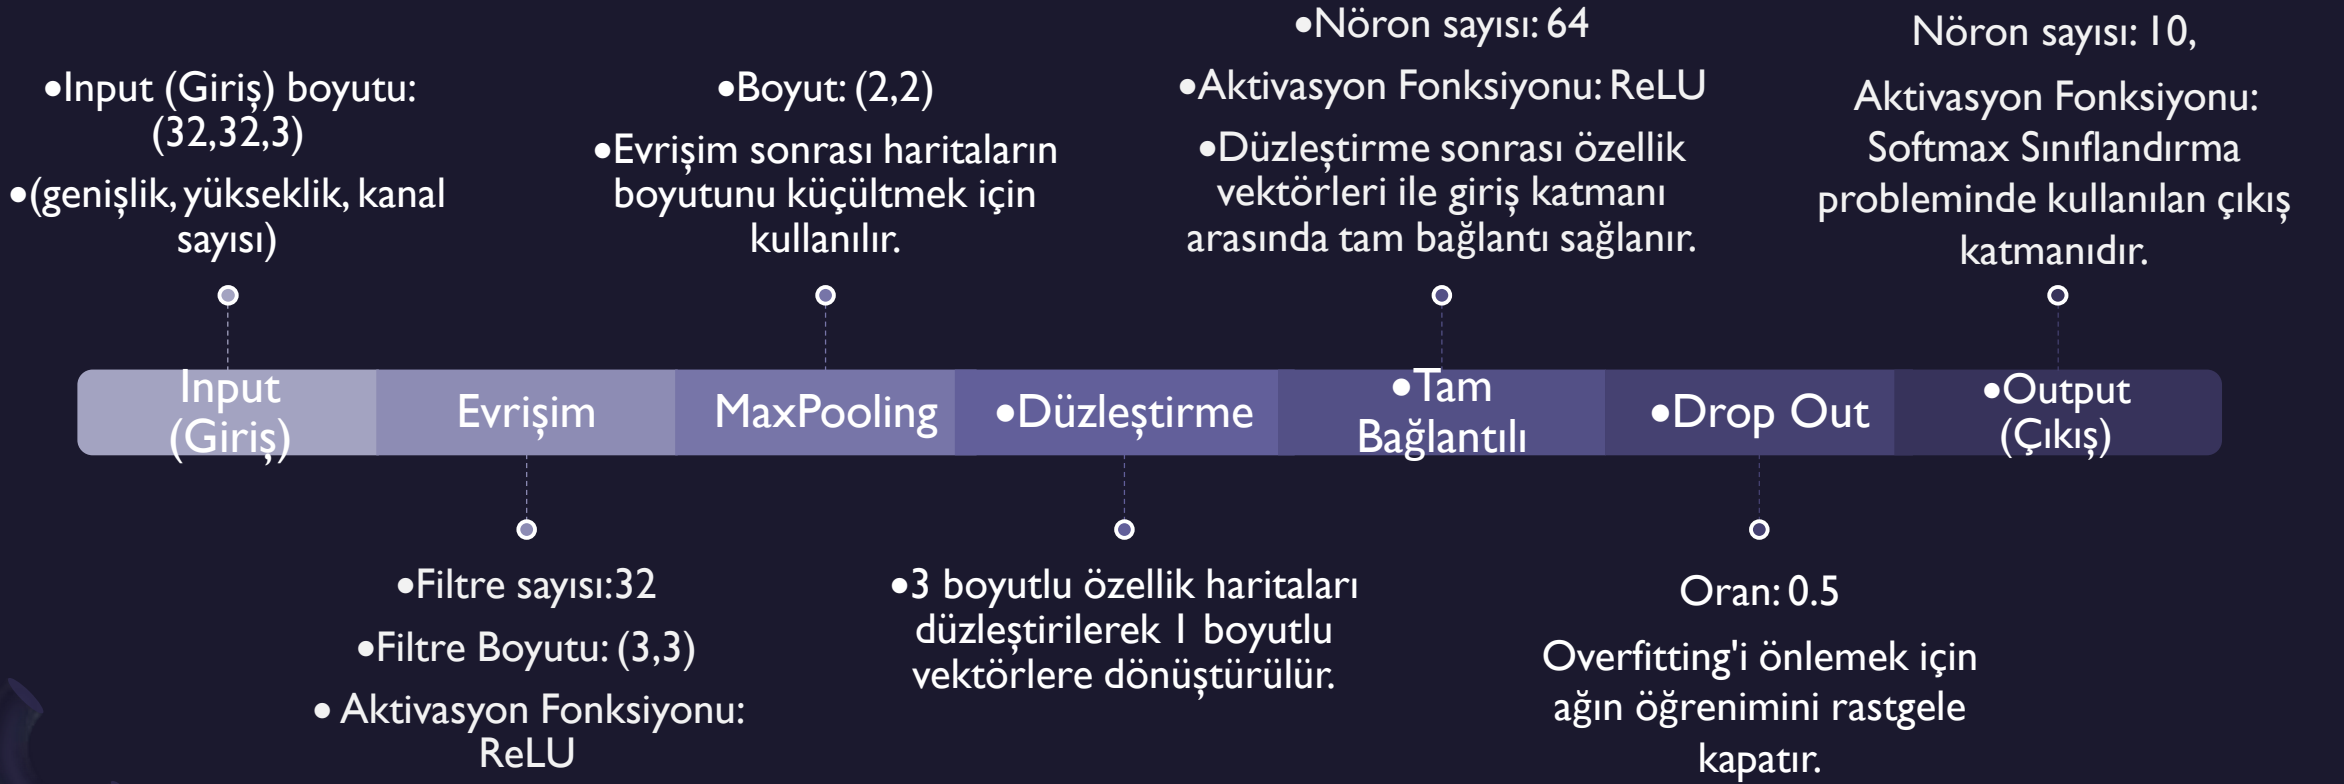
Normalizasyon öncesinde hazırlık amacıyla herhangi bir değer kontrol edilmek için plt.figure() plt.imshow(X_train[0]) ve plt.show() kullanarak ekrana yazdırılır.

```
x_train, x_test = x_train / 255.0, x_test / 255.0
```

```
from keras.utils import to_categorical  
  
y_train = to_categorical(y_train, num_classes=10)  
y_test = to_categorical(y_test, num_classes=10)
```

```
plt.figure()  
plt.imshow(x_train[0])  
plt.grid(False)  
plt.show()
```

CNN Model Katmanları



Model Geliştirme



Bu model geliştirme sürecinde kullanılan kütüphaneler:

- NumPy ve matplotlib.pyplot kütüphaneleri veri görselleştirme ve normalizasyonunda kullanılmıştır.
- Sciki-learn (sklearn) kütüphanesi RandomForestClassifier gibi makine öğrenmesi araçlarında kullanılmıştır.
- TensorFlow ve Keras kütüphaneleri kullanılarak CNN modeli geliştirilmiştir. TensorFlow, modelin oluşturulması, eğitilmesi ve değerlendirilmesi için temel altyapıyı sağlayarak Keras ise bu işlemleri daha yüksek seviyede ve kullanıcı dostu bir şekilde gerçekleştirmeye yardımcı oldu.

Bu araçlar ve kütüphaneler, projenin farklı aşamalarında kullanılarak modelin geliştirilmesi, eğitilmesi, değerlendirilmesi ve sonuçlarının görselleştirilmesi süreçlerine katkı sağlamıştır. Bu sayede, derin öğrenme modelinin başarıyla oluşturulması ve analiz edilmesi mümkün olmuştur.

Model Eğitimi

Model Eğitimi

- **Epoch Sayısı:** Model, 15 epoch boyunca eğitilmiştir. Her bir epoch, tüm veri setinin bir kere model tarafından geçirilmesini ifade eder.
- **Batch Size:** Model, her bir eğitim adımında 128 örnek kullanmıştır. Batch size, ağıın her adımda ne kadar veri işleyeceğini belirler.
- **Optimizasyon Algoritması:** Model, 'adam' optimizasyon algoritması kullanılarak eğitilmiştir. Adam, yaygın olarak kullanılan bir gradyan iniş optimizasyon algoritmasıdır.

Performans Değerlendirme

- **Değerlendirme Metrikleri:** Modelin performansını değerlendirmek için doğruluk (accuracy), kayıp (loss), kesinlik (precision) ve F1 skoru metrikleri kullanılmıştır.
- **Grafikler:** Modelin eğitim ve doğrulama sürecindeki doğruluk ve kayıp değerleri grafiklerle gösterilmiştir. Bu grafikler, modelin eğitim sürecindeki performansını görsel olarak gösterir.

Aşağıdaki kod parçası model eğitimi için kullanılmıştır.

```
hist = model.fit(datagen.flow(X_train, y_train, batch_size=128),  
                epochs=15,  
                validation_data=(X_test, y_test),  
                callbacks=[early_stopping])
```



Model Eğitimi Süreci boyunca deneyimler

Model eğitimi sürecinde en yüksek accuracy (doğruluk) değerini elde edebilmek için denenen metodlar arasında en başarı gösteren fit metodundaki batch_size ve epoch size değişikliği oldu.

Denemeler sonucunda epoch sayısının orantısız artışının modelde dengesiz ve kontrolsüz bir öğrenme yöntemi geliştirmesine ve modelin overfitting'e maruz kalmasına neden olmuştur.

Batch size ise 32, 64, 128, 256, ve 512 gibi tüm değerler denenerek geliştirilen model için 128 ve 256'nın en verimli batch size değerleri olduğuna karar verilmiştir.

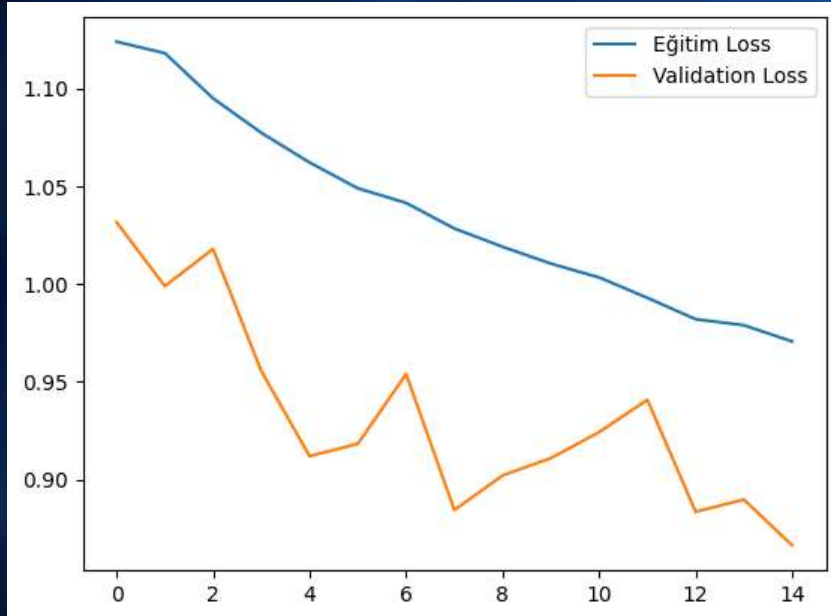
Modelin, içeriği bilinen bir görsel seçilerek tahminde bulunulması sağlanmış ve bu tahmin örneği de yanda verilmiştir.




Performans Değerlendirme ve Sonuçlar

- Performans Sonuçları: Modelin doğruluk, kayıp ve F1 skoru gibi performans metrikleri değerlendirilmiştir. Modelin doğruluğu %701.39 olarak belirlenmiştir.
- Örnek Tahminler: Modelin örnek tahminleri incelenmiş ve örnek görseller üzerindeki tahminleri doğrulukla karşılaştırılmıştır.


Aşağıda verilen grafiklerde de modelin 15 epoch süren öğrenme sürecindeki kararlılığı ve doğruluğu rahatlıkla teyit edilebilir haldedir.



Loss



Accuracy



Accuracy Evaluation

Uygulama Alanları ve Potansiyel Kullanım

- Uygulama Alanları: Modelimiz, görüntü sınıflandırma problemlerine odaklanmaktadır ve bu nedenle geniş bir uygulama alanına sahiptir.

Örneğin:

- Sağlık sektöründe, röntgen veya MR görüntülerinin otomatik sınıflandırılması ve hastalıkların tespiti için kullanılabilir.
- Otomotiv sektöründe, sürücüsüz araçların çevresel algılaması ve nesne tanıma için kullanılabilir.
- Güvenlik alanında, CCTV kameraları tarafından yakalanan görüntülerin analizi ve şüpheli aktivitelerin tespiti için kullanılabilir.
- Perakende sektöründe, ürünlerin otomatik tanımlanması ve stok yönetimi için kullanılabilir.

Tartışma ve Sonuç

Başarılar:

- Modelin eğitim sürecinde yüksek doğruluk elde edilmesi, özellikle veri artırma tekniklerinin kullanılmasıyla daha sağlam sonuçlar elde edilmesi.
- Görüntü sınıflandırma probleminin başarılı bir şekilde çözülmesi ve farklı sınıflar arasında net bir ayrım yapılabilmesi.

Zorluklar:

- Modelin karmaşıklığı ve derinliği nedeniyle eğitim sürecinin uzun sürmesi ve kaynak gereksinimlerinin artması.
- Veri setindeki dengesizlikler ve sınıf etiketlemesiyle ilgili sorunlar, özellikle az veriye sahip sınıfların doğruluk değerlerini etkilemesi.

Sonuç

- Bu projenin sonuçlarına göre, görüntü sınıflandırma probleminde CNN modeli kullanarak başarılı sonuçlar elde edilebilmektedir. Model, eğitim sürecinde doğruluk oranlarını artırmak için veri artırma tekniklerinin etkili bir şekilde kullanılmasını gerektirmektedir. Ancak, az veriye sahip sınıfların doğruluk değerlerini etkilemesi gibi zorluklarla da karşılaşmaktadır. Özetle, çalışmanın sonuçları, CNN modelinin görüntü sınıflandırma problemlerinde etkili bir şekilde kullanılabileceğini ve bu alandaki potansiyelini göstermektedir.



Özet

Bu sunumda, Cifar10 veri seti üzerinde bir CNN modeli geliştirdik. Modeli eğitim, veri görselleştirme, ön işleme, ve değerlendirme adımlarıyla analiz ettik. Modelin performansını doğruluk, F1 skoru, geri çağırma ve hassasiyet metrikleriyle değerlendirdik. Sonuçlar, CNN modellerinin görüntü sınıflandırma için etkili bir araç olduğunu gösteriyor.

Teşekkürler